

### Задание №1.3. К вопросу о линейности регрессии

На первых двух лекциях мы рассмотрели, как построить и обучить линейную модель данных для решения задачи регрессии. В этом упражнении мы познакомимся с тем, как строить и обучать нелинейную модель данных с помощью такого приема как **трансформация признаков** (feature mapping). Мы также увидим ряд ограничений этого подхода, с которыми в будущем нам предстоит разобраться.

#### Вопрос №1. Моделирование с помощью полиномов 3-й степени

[1.2 балла]

Пусть у нас есть обучающая выборка  $\{(x^{(i)}, y^{(i)})\}_{i=1}^m$ , где  $x^{(i)}, y^{(i)} \in \mathbb{R}$ . Мы бы хотели обучить на этих данных гипотезу, представляющую собой полином 3-й степени:  $h_\theta(x) = \theta_0 + \theta_1 x + \theta_2 x^2 + \theta_3 x^3$ . Ключевое наблюдение здесь состоит в том, что гипотеза  $h_\theta(x)$  по-прежнему остается линейной по своим параметрам  $\theta$ , несмотря на то, что она перестает таковой быть по входным данным  $x$ . Это позволяет нам использовать линейную регрессию для решения указанной задачи следующим образом.

Пусть  $\phi: \mathbb{R} \rightarrow \mathbb{R}^4$  – функция, отображающая входные данные  $x$  в 4-х мерный вектор:

$$\phi(x) = \begin{bmatrix} 1 \\ x \\ x^2 \\ x^3 \end{bmatrix} \in \mathbb{R}^4.$$

Для удобства будем вместо  $\phi(x)$  использовать вектор  $\hat{x} \in \mathbb{R}^4$ , где  $\hat{x}^{(i)} = \phi(x^{(i)})$ . Далее сконструируем новую обучающую выборку  $\{(\hat{x}^{(i)}, y^{(i)})\}_{i=1}^m$ , заменив исходные признаки  $x$  на новые вектора  $\hat{x}$ . Мы видим, что подгонка нелинейной гипотезы<sup>1</sup>  $h_\theta(x) = \theta_0 + \theta_1 x + \theta_2 x^2 + \theta_3 x^3$  к исходной обучающей выборке эквивалентна подгонке линейной гипотезы  $h_\theta(\hat{x}) = \theta_0 + \theta_1 \hat{x}_1 + \theta_2 \hat{x}_2 + \theta_3 \hat{x}_3$  к новой выборке, потому что

$$h_\theta(x) = \theta_0 + \theta_1 x + \theta_2 x^2 + \theta_3 x^3 = \theta_0 + \theta_1 \phi(x)_1 + \theta_2 \phi(x)_2 + \theta_3 \phi(x)_3 = \theta^T \hat{x}.$$

Иными словами, мы можем использовать линейную регрессию на новой обучающей выборке для нахождения параметров  $\theta_0, \dots, \theta_3$ .

Пожалуйста, выпишите:

1. функцию потерь  $J(\theta)$  линейной регрессии на новом датасете,
2. правило обновления вектора весов для пакетного градиентного спуска, используемого для обучения модели.

*Терминология:* данный метод в машинном обучении часто называют трансформацией признаков, при котором функция  $\phi$  отображает исходные признаки в новое пространство признаков. Для того чтобы различать старые и новые признаки, будем называть  $x$  атрибутами, а  $\phi(x)$  – признаками (хотя в разной литературе эти два понятия могут использоваться взаимозаменяемо).

#### Вопрос №2. Задача на программирование: кубическая регрессия

[1.2 балла]

Для этого задания мы будем использовать обучающую выборку из следующих файлов: train.csv, valid.csv и test.csv. Каждый файл содержит два столбца:  $x$  и  $y$ . В терминологии, описанной выше,  $x$  –

---

<sup>1</sup> В машинном обучении часто используют слово «подгонка» как синоним «обучение», в том смысле, что мы подгоняем модель под данные (fit a model to some dataset – подогнать модель под данные).

это атрибут (в данном случае одномерный), а  $y$  – результат (метка<sup>2</sup>). Ваша задача – реализовать линейную регрессию с помощью *нормальных уравнений*, используя трансформацию исходного атрибута в полином третьей степени. В файле `featuremap.py` приведен стартовый код.

Создайте точечную диаграмму обучающей выборки и отобразите на ней обученную гипотезу в виде плавной кривой.

*Примечание:* Предположим, что  $\hat{X}$  – это матрица трансформированной обучающей выборки. Иногда вы можете столкнуться с проблемой необратимости матрицы  $\hat{X}^T \hat{X}$ . Для численно стабильной реализации кода всегда используйте решатель `numpy.linalg.solve` для получения параметров напрямую вместо того, чтобы явно вычислять обратную матрицу, а затем умножать ее на  $\hat{X}^T y$ .

*Совет:* Возможно, вы захотите использовать `xlim` и `ylim`, чтобы установить разумные ограничения для отображаемых на графике областей.

---

**Вопрос №3. Задача на программирование: регрессия полиномом k-той степени** [1.2 балла]

Теперь мы распространим вышеизложенную идею на полиномы k-той степени, взяв  $\phi: \mathbb{R} \rightarrow \mathbb{R}^{k+1}$  следующего вида

$$\phi(x) = \begin{bmatrix} 1 \\ x \\ x^2 \\ \dots \\ x^k \end{bmatrix} \in \mathbb{R}^{k+1}.$$

Следуйте процедуре, описанной в предыдущем вопросе, и реализуйте алгоритм для  $k = 3, 5, 10, 20$ . Постройте график и включите кривые гипотез для каждого значения  $k$ , раскрасив их в разные цвета. Добавьте легенду в график, чтобы указать, какой цвет соответствует какому значению  $k$ .

Понаблюдайте, как меняется подгонка гипотезы к обучающему набору по мере увеличения  $k$ . Кратко прокомментируйте свои наблюдения.

---

**Вопрос №4. Задача на программирование: другие трансформации признаков** [1.2 балла]

Возможно, вы заметили, что для корректного моделирования данных требуется относительно высокая степень  $k$ , и это связано с тем, что обучающая выборка не может быть адекватно объяснена (т.е. аппроксимирована) полиномами низкой степени. Визуализируя данные, вы, возможно, поняли, что  $y$  можно хорошо аппроксимировать синусоидой. Фактически, данные для упражнения сгенерированы случайной функцией  $y = \sin(x) + \xi$ , где  $\xi$  – случайный шум с нормальным распределением. Обновите карту признаков  $\phi$ , включив в него синусоидальное преобразование следующим образом:

$$\phi(x) = \begin{bmatrix} 1 \\ x \\ x^2 \\ \dots \\ x^k \\ \sin(x) \end{bmatrix} \in \mathbb{R}^{k+2}.$$

С помощью обновленной карты признаков обучите модели линейной регрессии для значений  $k = 0, 1, 2, 3, 5, 10, 20$  и отобразите на графике полученные кривые гипотез.

---

<sup>2</sup> В задачах машинного обучения с учителем значения  $y$  иногда называются метками, так как с их помощью размечаются «правильные ответы» на данных.

Сравните полученные модели с предыдущими и кратко прокомментируйте заметные различия.

**Вопрос №5. Переобучение сложных моделей на небольших данных**

[1.2 балла]

В заключительном вопросе мы рассмотрим задачу прогнозирования на небольшом наборе данных с гораздо меньшим количеством примеров, представленном в следующем файле: small.csv.

Мы проанализируем, что происходит, когда количество признаков начинает превышать количество примеров в обучающей выборке. Запустите свой алгоритм на этом небольшом наборе данных, используя следующую карту признаков:

$$\phi(x) = \begin{bmatrix} 1 \\ x \\ x^2 \\ \dots \\ x^k \end{bmatrix} \in \mathbb{R}^{k+1}$$

с  $k = 1, 2, 5, 10, 20$ .

Постройте график полученных кривых гипотез. Понаблюдайте, как меняется подгонка под обучающую выборку по мере увеличения  $k$ . Прокомментируйте то, что вы наблюдаете.

*Замечание:* Явление, которое вы наблюдаете, когда модель начинает очень хорошо предсказывать саму обучающую выборку, но в остальных точках начинает вести себя неадекватно, называется переобучением (overfitting). Интуитивно можно считать, что, когда объем имеющихся у вас данных невелик по сравнению с выразительной способностью модели, это приводит к переобучению.

Грубо говоря, функция гипотезы становится "очень гибкой", и ее можно легко заставить проходить через все примеры обучающей выборки, пусть даже и не очень естественным образом. Модель начинает объяснять шумы в данных, которые объяснять не следовало бы. Это приводит к снижению обобщающей способности модели.